

姓名：袁佳逸

学号：2400010962

Transformer 作业实验报告

理解数据流

请根据 `nmt_de2en.py` 的实现，完成以下任务：

`batch size` 记为 `B`，源语言序列长度记为 `S`，目标语言输入序列长度记为 `T`，词嵌入维度记为 `E`，目标语言词表大小记为 `V_tgt`。

主要 Tensor 的 shape

请补全下表：

(提示：可以在代码中直接打印 `shape` 进行观察)

Tensor	shape	含义或作用
<code>src</code>	<code>[S, B]</code>	源语言 token id 序列
<code>tgt</code>	<code>[T + 1, B]</code>	目标语言 token id 序列
<code>tgt_input</code>	<code>[T, B]</code>	目标语言输入 token id 序列
<code>src_emb</code>	<code>[S, B, E]</code>	<code>src</code> 的词嵌入结果
<code>tgt_emb</code>	<code>[T, B, E]</code>	<code>tgt_input</code> 的词嵌入结果
<code>src_mask</code>	<code>[S, S]</code>	用于控制源语言 token 之间哪些位置可以互相注意，本实验中为全 0 矩阵
<code>tgt_mask</code>	<code>[T, T]</code>	用于控制目标语言 token 之间哪些位置可以互相注意
<code>src_padding_mask</code>	<code>[B, S]</code>	源语言序列的填充掩码
<code>tgt_padding_mask</code>	<code>[B, T]</code>	目标语言序列的填充掩码
<code>outs</code>	<code>[T, B, V_tgt]</code>	模型输出的 logits
<code>logits</code>	<code>[T, B, V_tgt]</code>	模型输出的 logits
<code>tgt_out</code>	<code>[T, B]</code>	目标语言输出 token id 序列

请回答：

Q1：在验证集上测试模型和调用 `translate` 函数都会进行翻译，请指出它们运行逻辑上的主要不同点。

A1：

- 验证集测试：使用 `tgt` 作为输入 Decoder，一次性并行得到所有位置的 `logits`，再与 `tgt_out` 计算 `loss` 和准确率，评估模型性能
- 调用 `translate` 函数：从 `BOS` 开始每次只生成一个 `token`，再把生成的 `token` 接回去继续生成，直到遇到 `EOS` 或达到最大长度，逐步生成目标

Encoder & Decoder

请根据 `transformer.py` 中的定义，判断 Encoder 和 Decoder 分别用到了哪些信息，并补全下表。

是否用到了以下信息	Encoder	Decoder
<code>src_emb</code>	Y	N
<code>tgt_emb</code>	N	Y
<code>src_mask</code>	Y	N
<code>tgt_mask</code>	N	Y
<code>memory</code>	N	Y

请回答：

Q2：memory 的 shape 是多少？（使用 `B`，`S`，`T`，`E` 等记号表示）

A2: `[S, B, E]`

Q3: Encoder 和 Decoder 分别有几层？

A3: Encoder 有 3 层，Decoder 有 3 层。

Q4: 请把单层 Encoder 和单层 Decoder 的前向传播过程的代码粘贴到下方。

A4:

```
# EncoderLayer forward
def forward(self, src: Tensor, src_mask: Optional[Tensor] = None,
src_key_padding_mask: Optional[Tensor] = None) -> Tensor:
    """Pass the input through the encoder layer.

    Args:
        src: the sequence to the encoder layer (required).
        src_mask: the mask for the src sequence (optional).
        src_key_padding_mask: the mask for the src keys per batch (optional).

    Shape:
        see the docs in Transformer class.
    """
    src2 = self.self_attn(src, src, src, attn_mask=src_mask,
                           key_padding_mask=src_key_padding_mask)[0]
    src = src + self.dropout1(src2)
    src = self.norm1(src)
    src2 = self.linear2(self.dropout(self.activation(self.linear1(src))))
    src = src + self.dropout2(src2)
```

```
src = self.norm2(src)
return src
```

```
# DecoderLayer forward
def forward(self, tgt: Tensor, memory: Tensor, tgt_mask: Optional[Tensor] = None,
memory_mask: Optional[Tensor] = None,
            tgt_key_padding_mask: Optional[Tensor] = None,
memory_key_padding_mask: Optional[Tensor] = None) -> Tensor:
    r"""Pass the inputs (and mask) through the decoder layer.

    Args:
        tgt: the sequence to the decoder layer (required).
        memory: the sequence from the last layer of the encoder (required).
        tgt_mask: the mask for the tgt sequence (optional).
        memory_mask: the mask for the memory sequence (optional).
        tgt_key_padding_mask: the mask for the tgt keys per batch (optional).
        memory_key_padding_mask: the mask for the memory keys per batch
(optional).

    Shape:
        see the docs in Transformer class.
    """
    tgt2 = self.self_attn(tgt, tgt, tgt, attn_mask=tgt_mask,
                        key_padding_mask=tgt_key_padding_mask)[0]
    tgt = tgt + self.dropout1(tgt2)
    tgt = self.norm1(tgt)
    tgt2 = self.multihead_attn(tgt, memory, memory, attn_mask=memory_mask,
                        key_padding_mask=memory_key_padding_mask)[0]
    tgt = tgt + self.dropout2(tgt2)
    tgt = self.norm2(tgt)
    tgt2 = self.linear2(self.dropout(self.activation(self.linear1(tgt))))
    tgt = tgt + self.dropout3(tgt2)
    tgt = self.norm3(tgt)
    return tgt
```

Embedding 实验

删除 EOS 的影响

本部分建议在 `nmt_de2en.py` 上完成。德英数据集较小，训练更快，适合做对比实验。

修改 `tensor_transform`，删除句尾的 `EOS_IDX`，重新训练模型，并观察翻译结果，填写下表：

设置	最终训练 loss	最终验证 loss	原句	翻译结果	现象
保留 EOS	0.783	1.941	Eine Gruppe von Menschen steht vor einem Igloo.	A group of people stand in front of an igloo.	正常

设置	最终训练 loss	最终验证 loss	原句	翻译结果	现象
删除 EOS	0.829	2.064	Eine Gruppe von Menschen steht vor einem Iglu.	A group of people stand in front of an igloo . UTEP . birdie .	异常结尾

词嵌入观察

训练 `nmt_zh2en.py` 模型，并参考 `docs/cli_tools.md` 中的命令行说明，查询若干词在 embedding 空间中的最近邻。

请选择至少 5 个英文或中文词进行观察。

查询词	最相近 token 1	最相近 token 2	最相近 token 3
apple	Pandemic	Agreed	Animal
苹果	安倍	东京	马纳福特
spring	night	week	March
语言	种族	文字	言语
自然	物竞天择	本性	天生

温度实验

本部分在 `nmt_zh2en.py` 上完成。

温度会影响生成结果，温度越高越自由，翻译模型一般会让温度等于 0（greedy decode）。请选择至少 3 个中文句子，每个句子分别测试 4 种温度，并记录结果。

`docs/cli_tools.md` 中记录了交互式翻译和设置温度的方法。修改温度不需要重新训练模型，完成一次训练后会直接加载已有的 checkpoint。

中文输入	temperature	英文输出
但目前这方面的投入还远远不够。	0	But this is far from enough .
但目前这方面的投入还远远不够。	0.5	But the investments are far from enough .
但目前这方面的投入还远远不够。	1	But this is far from enough .
但目前这方面的投入还远远不够。	1.5	But this demand is much enough mutual .
新技术支持的金融工具为某些人赚取巨额利润创造了机遇。	0	Financial tools that support new technology create opportunities for some to receive large profits .
新技术支持的金融工具为某些人赚取巨额利润创造了机遇。	0.5	Financial tools that are backed by new technology create opportunities for some to earn large profits .
新技术支持的金融工具为某些人赚取巨额利润创造了机遇。	1	Financial tools pro - technology support create opportunities for some happen shrinking profits .

中文输入	temperature	英文输出
新技术支持的金融工具为某些人赚取巨额利润创造了机遇。	1.5	recovered sent opportunities equally rapidly best - reap least starting shrinking financial contain significant way enabled everyone to package grew profit game
反恐国际合作显著增强，部分是因为，各国政府都觉得需要在这领域加强合作，尽管它们在其他领域颇有分歧。	0	The international cooperation on terrorism has increased significantly , partly because governments feel that need to strengthen cooperation in this area , though they are divided in other areas .
反恐国际合作显著增强，部分是因为，各国政府都觉得需要在这领域加强合作，尽管它们在其他领域颇有分歧。	0.5	International cooperation on terrorism has increased significantly , partly because governments feel that need to strengthen cooperation in this area , though they are divided on other areas .
反恐国际合作显著增强，部分是因为，各国政府都觉得需要在这领域加强合作，尽管它们在其他领域颇有分歧。	1	International cooperation on terrorism universal , partly because their governments shortage to strengthen cooperation in this area , though they are and divided over other areas .
反恐国际合作显著增强，部分是因为，各国政府都觉得需要在这领域加强合作，尽管它们在其他领域颇有分歧。	1.5	Treasury whole shortage balance reached grow is tight , partly with fear about and more cooperation decade in resistance , but in no way they exports more .

超参数修改

本部分在 `nmt_de2en.py` 上完成。请使用相同数据集和相同训练轮数，对比不同模型规模对训练速度、loss、显存占用和过拟合情况的影响。

请分别训练以下三组超参数。

配置	EMB_SIZE	NHEAD	FFN_HID_DIM	Encoder layers	Decoder layers
Tiny	128	4	256	2	2
Base	512	8	512	3	3
Wide	512	8	1024	4	4

训练脚本会在 `log/de2en/` 下导出 CSV，请根据 CSV 填写下表。

配置	最终 train loss	最终 val loss	单 epoch 平均时间	最大显存占用
Tiny	2.0085060055560477	2.2060405239462852	12.13s	652.3896484375
Base	0.7826906429513436	1.9413174018263817	39.08s	1465.8642578125

配置	最终 train loss	最终 val loss	单 epoch 平均时间	最大显存占用
Wide	0.8383088318655669	1.8997707590460777	52.03s	1881.650390625

Q5: 请根据实验结果，简述不同模型规模产生的影响。

A5:

- 模型越大，训练时间和显存占用越高，说明更大的模型会明显带来更高的计算和存储成本。
- 较大的模型通常具有更强的拟合能力，相比于 Tiny, Base 和 Wide 的验证集表现明显更好，说明增大模型规模确实有助于提升翻译效果。
- Base 和 Wide 在后期都出现了轻微过拟合现象：训练损失继续下降，但验证损失在最优点之后不再明显改善，甚至略有波动。相比之下，Tiny 虽然不太容易过拟合，但主要问题是欠拟合。
- Tiny 训练最快、资源消耗最少，但性能不足；Wide 性能最好但代价最高，而且相对 Base 的提升有限；Base 在性能和训练成本之间取得了较好的平衡，因此是这组实验中性价比最高的配置。